

matlab_SVM 视频讲解_2

线性可分模式的最优超平面的详细推导过程:

考虑训练样本 $\{x_i, y_i\}_{i=1}^N$, 其中 x_i 是输入模式的第 i 个样本, $y_i \in \{-1, +1\}$.

设用于分离的超平面方程是:

$$w \bullet x + b = 0 \quad (1)$$

其中 w 是超平面的法向量, b 是超平面的常数项.

[虚幻的叫法 w 是可调的权值向量, b 是偏置, 上面的是 w 和 b 的数学本质]

现在的目的就是寻找最优的分类超平面, 即寻找最优的 w 和 b . 设最优

的 w 和 b 为 w_0 和 b_0 , 则最优的分类超平面为:

$$w_0 \bullet x + b_0 = 0 \quad (2)$$

若得到上面的最优分类超平面, 就可以用其来对测试集进行预测了.

设测试集合为 $\{t_i\}_{i=1}^M$, 则用最优分类超平面预测出的测试集的标签为:

$$t_i_label = \text{sgn}(w_0 \bullet t_i + b_0) \quad (3)$$

上面是明确问题目的性, 也就是到底要解决什么问题, 要做什么.

SVM 的主要思想是建立一个超平面作为决策曲面, 使得正例和反例之间的隔离边缘被最大化.

即最优分类超平面等价于求最大间隔

定义 支持向量

满足下面条件的特殊数据点 (x_i, y_i) 称为支持向量:

$$w \bullet x_i + b = -1, y_i = -1 \quad (4)$$


or

$$w \bullet x_i + b = 1, y_i = +1 \quad (5)$$

支持向量是那些最靠近决策面的数据点, 这样的数据点是最难分类的,

因此,它们和决策面的最优位置直接相关.

推导最大间隔:



$$\begin{aligned}
 & w \cdot x_1 + b = 1 \quad w \cdot x_2 + b = -1 \\
 \Rightarrow & w \cdot (x_1 - x_2) = 2 \\
 \Rightarrow & \frac{w}{\|w\|} (x_1 - x_2) = \frac{2}{\|w\|} \\
 \max \frac{2}{\|w\|} \Leftrightarrow \min \|w\| \Leftrightarrow \min \frac{\|w\|^2}{2}
 \end{aligned}$$

设 x_1, x_2 如图,则正反例的间隔为 $dis = \frac{w}{\|w\|} \cdot (x_1 - x_2)$. 又

$$w \cdot x_1 + b = 1 \quad (6)$$

$$w \cdot x_2 + b = -1 \quad (7)$$

$$\text{所以 } dis = \frac{w}{\|w\|} \cdot (x_1 - x_2) = \frac{2}{\|w\|}.$$

$$\text{则 } \frac{2}{\|w\|} \text{ 最大化} \Leftrightarrow \|w\| \text{ 最小化} \Leftrightarrow \frac{\|w\|^2}{2} \text{ 最小化}.$$

且对于任意的 (x_i, y_i) 有[可以证明不详说]:

$$\begin{cases} w \cdot x_i + b \leq -1, y_i = -1 \\ w \cdot x_i + b \geq 1, y_i = 1 \end{cases} \quad \text{即(结合一下)} \quad y_i(w \cdot x_i + b) \geq 1 \quad (8)$$

so. 寻找最优超平面即正反例间隔最大化问题,最终归结为一个二次

最规划问题[原问题 primal pro]:

$$\min_w \frac{\|w\|^2}{2}$$

$$\text{s.t. } y_i(w \bullet x_i + b) \geq 1, \forall i = 1, 2, \dots, N$$

使用 Lagrange 乘子法可以解决上述问题.

首先建立 Lagrange 函数:

$$J(w, b, a) = \frac{1}{2} w^T w - \sum_{i=1}^N a_i [y_i (w \bullet x_i + b) - 1] \quad (9)$$

其中辅助非负变量 a_i 称为 Lagrange 乘子.

对 w 和 b 求偏导并置零,有

$$\frac{\partial J}{\partial w} = 0 \Leftrightarrow w = \sum_{i=1}^N a_i y_i x_i \quad (10)$$

$$\frac{\partial J}{\partial b} = 0 \Leftrightarrow \sum_{i=1}^N a_i y_i = 0 \quad (11)$$

再整理 J 最终可以得到原问题的对偶问题(dual pro):

$$\max_a Q(a) = J(w, b, a) = \sum_{i=1}^N a_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N a_i a_j y_i y_j x_i^T x_j$$

$$\text{s.t. } \sum_{i=1}^N a_i y_i = 0, a_i \geq 0$$

对偶问题完全是根据训练数据来表达的.而且,函数 $Q(a)$ 的最大化仅依赖于输入模式点积的集合 $\{x_i^T x_j\}$

求解出求偶问题的最优解,设用 a_i^* 表示最优的 Lagrange 乘子,则此时原问题的最优解为:

$$w_0 = \sum_{i=1}^N a_i^* y_i x_i$$

$$b_0 = 1 - w_0^T x^{(s)}, y^{(s)} = 1$$

至此原问题就得到了解决!

则判断函数为:

$$\text{sgn}(\sum_{i=1}^N a_i^* y_i x_i x + b), \text{其中 } \mathbf{x} \text{ 为测试集中的样本.}$$